

贝叶斯统计推断 · 广告点击率分析

小组编号: Team 12

小组成员及贡献分工

姓名	角色与贡献
王金波	实验代码、第 3 部分二项似然函数
何漪雯	第 1 部分业务场景概述、第 2 部分图
李敏	第 2 部分先验论证、第 5 部分贝叶斯
丁玲	第 4 部分后验计算、报告整合
刘海龙	第 6 部分上线建议、报告审查

目 录

1	业务场景概述	1
1.1	项目背景	1
1.2	实验数据	1
2	贝塔先验的选择与论证 (Prior Justification)	2
2.1	先验分布形式	2
2.2	超参数 α 与 β 的选取	2
2.3	超参数的业务含义解读	2
2.4	先验分布对 2% ~ 8% 区间的匹配性验证	3
2.5	先验概率密度分布图	3
3	二项似然函数 (Binomial Likelihood)	3
3.1	二项似然函数原理阐述	3
3.2	本次试点测试的似然函数表达式	4
3.3	似然函数定义	4
3.4	似然函数曲线	5
4	后验计算和可视化 (Posterior Calculation and Visualization)	6
4.1	共轭更新计算	6
4.2	后验均值计算及与 observed CTR 的区分	7
4.3	不确定性的量化变化	7
4.4	先验分布与后验分布的比较	8
4.5	信念更新解释	9
5	可信区间与贝叶斯解释 (Credible Interval and Bayesian Interpretation)	9
5.1	概念区分: 可信区间 vs 置信区间	9
5.2	95% 可信区间的计算	9
5.3	贝叶斯语言解读	10
5.4	直接的后验概率陈述	10
5.5	面向业务场景的通俗解读	11
6	上线建议 (Launch Decision)	11
6.1	最终建议结论	11
6.2	贝叶斯分析核心依据	12
6.3	结合小样本特性的业务决策权衡	12
6.4	先验敏感性分析 (结论稳健性检验)	13
7	小组成员角色与贡献	14
	附录 A 完整可运行代码	14

关于本报告的可复现性

完整可运行代码：https://github.com/woodywang/hpu/blob/master/6000-2/DSCI6000_hw2.py

报告中所有数值结果与三张图表均由该脚本一次运行直接生成，可完整复现；代码全文见附录 A。图片文件位于脚本同级 `figures/` 目录，由脚本自动输出，重新运行脚本即可刷新报告全部插图。

运行环境：Python 3 + numpy / scipy / matplotlib（可直接粘贴至 Google Colab 运行，无需额外配置）。

1 业务场景概述

1.1 项目背景

一家手机游戏工作室正在测试一则新的首页横幅广告，希望评估该广告是否能够提高用户点击率，并决定是否将其推广至全站。核心评估指标为点击率（Click-Through Rate, CTR）= 用户点击次数 / 广告展示次数 $\times 100\%$ 。根据行业历史基准，同类广告的 CTR 通常稳定在 $2\% \sim 8\%$ 之间，这一区间构成了团队的先验信念，因此可作为贝叶斯分析中的先验信息（Prior Information）。

1.2 实验数据

工作室开展了小规模试点测试，本次试点实验共收集到表 1 所列数据。按样本计算，观测 CTR 为 $18/200 \times 100\% = 9.0\%$ 。

表 1 试点测试观测数据

指标	数值
广告展示次数 n	200
用户点击次数 z	18
实际观测 CTR	9.0%

但该 9.0% 仅是 200 次展示下的样本均值，受随机波动影响较大，未必代表真实长期 CTR。若直接以此作为全量上线的依据，可能高估或低估广告效果。因此，需要在决策前进行贝叶斯更新：将行业历史先验（ $2\% \sim 8\%$ ）与本次试点数据（200 次展示、18 次点击）相结合，得出真实 CTR 的后验分布。该分布能量化不确定性，为是否全量推广提供更稳健的概率化证据。

2 贝塔先验的选择与论证 (Prior Justification)

2.1 先验分布形式

设真实 CTR 参数为 θ ($\theta \in [0, 1]$), 我们为其赋予 Beta 先验分布:

$$\theta \sim \text{Beta}(\alpha, \beta).$$

选择 Beta 分布的原因有二: 其一, Beta 分布定义域为 $(0, 1)$, 与 CTR 的概率属性天然匹配; 其二, Beta 分布是二项分布的共轭先验, 可保证后验分布解析可求, 无需数值模拟。

2.2 超参数 α 与 β 的选取

行业历史数据显示同类广告 CTR 稳定在 2% ~ 8% 之间。为匹配该区间, 我们采用矩估计法确定超参数: 取先验均值位于区间中值 5%, 并设定先验标准差 $\sigma \approx 0.015$, 使得约 95% 的先验质量落入 2% ~ 8% 范围 (利用正态近似下均值 $\pm 2\sigma$ 覆盖 95% 的原则)。

由 Beta 分布的性质, 其均值为 $\frac{\alpha}{\alpha + \beta}$, 方差为 $\frac{\alpha\beta}{(\alpha + \beta)^2(\alpha + \beta + 1)}$ 。令 $\mu = 0.05$ 、 $\sigma = 0.015$, 并设先验强度 $n = \alpha + \beta$, 由

$$\sigma^2 = \frac{\mu(1 - \mu)}{n + 1}$$

解得 $n \approx 210$ 。进而得出

$$\alpha = \mu \cdot n = 0.05 \times 210 = 10.5, \quad \beta = (1 - \mu) \cdot n = 0.95 \times 210 = 199.5.$$

根据以上计算结果, 并为便于后文的“伪计数”(pseudo-count)解释, 将超参数取整设定为 $\alpha = 10$ 、 $\beta = 200$, 即 $\alpha + \beta = 210$ 。此时先验均值 $\alpha/(\alpha + \beta) = 10/210 = 0.0476$, 即 4.76% (略低于目标值 5%, 系取整所致; 若要求均值恰为 5.00%, 可直接采用 $\text{Beta}(10.5, 199.5)$, Beta 分布并不要求参数为整数)。该先验分布在 $[2\%, 8\%]$ 区间上的概率质量为 96.45%, 符合超参数 α 和 β 的选取标准。

最终选取 $\theta \sim \text{Beta}(\alpha = 10, \beta = 200)$ 作为先验分布。

2.3 超参数的业务含义解读

在 Beta 分布中, α 和 β 可直观地理解为“有效先验样本中的成功次数和失败次数”:

- **伪点击** $\alpha = 10$: 相当于在历史经验中, 我们“见过”约 10 次点击;
- **伪未点击** $\beta = 200$: 相当于在历史经验中, 我们“见过”约 200 次未点击;
- **先验强度** $\alpha + \beta = 210$: 相当于先验信息等效于 210 次历史展示所积累的认知强度。

这一等效样本量规模适中, 既体现了行业历史基准的参考价值, 又不会过于强势, 确保后续试点数据 (200 次展示) 有足够空间对先验进行有效更新。

2.4 先验分布对 2% ~ 8% 区间的匹配性验证

2.4.1 (1) 先验均值验证

$E[\theta] = \alpha/(\alpha + \beta) = 10/210 = 0.0476$ ，即 4.76%。该值接近 2% ~ 8% 区间的中点 (5%)，符合行业基准预期。

2.4.2 (2) 概率质量验证

从两个互补的角度验证先验与行业区间的吻合程度。

角度一：先验的 95% 等尾概率区间。计算 $\text{Beta}(10, 200)$ 的分位数：

- 2.5% 分位数（下限）= 0.0232，即 2.32%；
- 97.5% 分位数（上限）= 0.0802，即 8.02%。

即先验的 95% 概率质量落在 [2.32%, 8.02%]，与行业区间 [2%, 8%] 几乎重合。

角度二：行业区间上的概率质量。直接计算先验落入行业区间的概率：

$$P(0.02 \leq \theta \leq 0.08) = F(0.08) - F(0.02) = \mathbf{96.45\%}.$$

两个角度互为印证：在观测任何新数据之前，我们已有 96.45% 的把握认为该广告的真实 CTR 处于行业历史基准区间 2% ~ 8% 内，这一定量结论精准表达了团队的先验信念。（注意两个数字描述的是不同对象：95% 是“先验区间”的覆盖概率，96.45% 是“行业区间”上的概率质量，两者接近正说明先验设定精准。）

2.5 先验概率密度分布图

图 1 为点击率 (CTR) 的先验概率密度分布图。横轴是真实点击率，纵轴是概率密度。蓝色曲线表示点击率的先验分布，基于行业历史经验形成；浅蓝色区域表示 95% 先验概率区间，即有 95% 可能真实点击率落在此区间；红色虚线表示先验分布均值 4.76%，落在行业历史 CTR 通常所在的 2% ~ 8% 区间（灰色区域）内，表明先验设定合理参考了行业常规情况。

3 二项似然函数 (Binomial Likelihood)

3.1 二项似然函数原理阐述

对于给定的展示次数 n 和真实点击率 θ ，点击次数 z 服从二项分布 $\text{Binomial}(n, \theta)$ 。二项分布的概率质量函数为

$$P(Z = z | n, \theta) = \binom{n}{z} \theta^z (1 - \theta)^{n-z}, \quad \binom{n}{z} = \frac{n!}{z!(n-z)!},$$

其中 $\binom{n}{z}$ 是组合数。在似然函数的视角下，我们将 z 视为已观测到的常数， θ 视为变量，所以似然函数 $L(\theta)$ 就是在给定观测数据下关于参数 θ 的函数。注意组合数 $\binom{n}{z}$ 不依赖于 θ ，因此它只是一个不影响 θ 相对可能性的归一化常数——这也正是后验分布只由 $\theta^z(1 - \theta)^{n-z}$ 这一核心项与先验相乘决定的原因。




图 1 先验概率密度分布图：Beta(10, 200) 的 PDF、均值与 95% 概率区间

3.2 本次试点测试的似然函数表达式

已知在试点测试中，观察值 $n = 200$ 、 $z = 18$ ，那么似然函数 $L(\theta)$ 的表达式为

$$L(\theta) = \binom{200}{18} \theta^{18} (1 - \theta)^{200-18} = \frac{200!}{18! (200 - 18)!} \theta^{18} (1 - \theta)^{182}.$$

该似然函数的物理含义是：在任意给定真实点击率 θ 的前提下，观测到本次试点 18 次点击、182 次未点击结果的相对可能性。

3.3 似然函数定义

定义本次试点测试的似然函数的代码如下。我们同时给出手写公式与 `scipy.stats.binom` 两种实现，互为交叉验证：

```
1 # 定义二项式似然函数与对数似然函数 stated
2
3 def binomial_likelihood(theta, n, z):
4     """Likelihood of observing z clicks in n impressions given θ."""
5
6     comb = math.factorial(n) / (math.factorial(z) * math.factorial(n - z))
7     return comb * (theta**z) * ((1 - theta)**(n - z))
8
9 def binomial_log_likelihood(theta, n, z):
10    """Log-likelihood of observing z clicks in n impressions given θ."""
11
12    return stats.binom.logpmf(z, n, theta)
13
14 # 手写公式与 scipy.stats.binom.pmf 互为交叉验证，应得到相同结果
15 lik_manual = binomial_likelihood(sample_ctr, n_impressions, n_clicks)
16 lik_scipy = stats.binom.pmf(n_clicks, n_impressions, sample_ctr)
```

```

17 loglik = binomial_log_likelihood(sample_ctr, n_impressions, n_clicks)
18
19 print(f'''Likelihood of observing {n_clicks} clicks in {n_impressions} impressions at  $\theta = \{sample\_ctr:.2\}$ :
20     manual formula      = {lik_manual:.10f}
21     scipy binom.pmf     = {lik_scipy:.10f}
22     log-likelihood      = {loglik:.6f}    (= ln {lik_manual:.6f})''')
23
24 # 定义二项式似然函数与对数似然函数 completed

```

计算结果：

```

Likelihood of observing 18 clicks in 200 impressions at  $\theta = 9.00\%$ :
    manual formula      = 0.0981126045
    scipy binom.pmf     = 0.0981126045
    log-likelihood      = -2.321639    (= ln 0.098113)

```

两种实现得到完全一致的似然值 $L(0.09) = 0.0981$, 对数似然为 $\ln(0.0981) = -2.3216$ (实际建模中常用对数似然, 因为连乘会迅速下溢, 取对数后化为求和, 数值上更稳定)。

3.4 似然函数曲线

将 θ 在 $(0, 0.2)$ 上取值并逐点计算 $L(\theta)$, 即可画出似然函数曲线:

```

1 # 绘制二项似然函数曲线图 stated
2
3 # 似然函数是关于 $\theta$ 的函数: 给定观测数据(200次展示, 18次点击), 不同 $\theta$ 值的相对合理性
4 lik_curve = stats.binom.pmf(n_clicks, n_impressions, theta)
5
6 fig, ax = plt.subplots()
7 ax.plot(theta, lik_curve, color='green', label='Likelihood L( $\theta$ )')
8 ax.fill_between(theta, lik_curve, color='green', alpha=0.12)
9
10 # 似然函数在 $\theta = 18/200 = 9\%$ 处取得最大值 (最大似然估计MLE)
11 ax.axvline(sample_ctr, color='black', linestyle='--', linewidth=2,
12            label=f'MLE = observed CTR = {sample_ctr:.2%}')
13
14 ax.set_xlabel('True CTR ( $\theta$ )')
15 ax.set_ylabel('Likelihood L( $\theta$ ) = P(z=18 | n=200,  $\theta$ )')
16 ax.set_title('Binomial Likelihood of 18 Clicks out of 200 Impressions')
17 ax.legend(fontsize=11)
18 plt.tight_layout()
19 save_figure('fig2_likelihood.png') # 保存图片供报告引用
20 plt.show()
21
22 # 绘制二项似然函数曲线图 completed

```

图 2 展示了在观测数据固定为“200 次展示、18 次点击”的条件下, 似然函数 $L(\theta)$ 随 θ 的变化。曲线在 $\theta = 18/200 = 9\%$ (黑色虚线) 处取得最大值, 该点即最大似然估计 (MLE), 也就是不借助任何先验信息、仅由数据本身给出的 CTR 估计。

需要强调的是, **似然函数不是 θ 的概率分布**: 它在 θ 上的积分并不等于 1, 纵轴表示的是“在该 θ 下观测到当前数据的概率”, 而非“ θ 取该值的概率”。要得到关于 θ 的




图 2 二项似然函数曲线图： $L(\theta)$ 在 $\theta = 9\%$ 处取得最大值（MLE）

概率陈述，必须按贝叶斯定理把它与先验相乘并归一化，这正是第 4 部分要做的事。

似然函数 $L(\theta)$ 能告诉我们在给定观测数据（200 次展示，18 次点击）的情况下，不同的 θ 值作为真实点击率的相对合理性。具体来说，似然函数值越大的 θ 值，意味着在该 θ 取值下观测到当前数据的可能性越高，即该 θ 值作为真实点击率越合理；似然函数值越小的 θ 值，意味着在该 θ 取值下观测到当前数据的可能性越低，即该 θ 值作为真实点击率越不合理。

4 后验计算和可视化 (Posterior Calculation and Visualization)

4.1 共轭更新计算

我们已知先验分布选择为 Beta 分布。根据共轭分布的性质，当似然函数为二项分布时（本次广告点击测试符合二项分布，即只有点击和未点击两种结果），后验分布也为 Beta 分布。

解析推导：由贝叶斯定理，后验正比于先验与似然之积（分母 $P(z)$ 不含 θ ，仅起归一化作用，可略去）。将 Beta 先验的核项 $\theta^{\alpha-1}(1-\theta)^{\beta-1}$ 与二项似然的核项 $\theta^z(1-\theta)^{n-z}$ 相乘：

$$p(\theta | z) \propto p(\theta) L(\theta) \propto \theta^{\alpha-1}(1-\theta)^{\beta-1} \cdot \theta^z(1-\theta)^{n-z} = \theta^{(\alpha+z)-1}(1-\theta)^{(\beta+n-z)-1}.$$

最右端恰好是 $\text{Beta}(\alpha + z, \beta + n - z)$ 的概率密度核，故后验必为

$$\theta | z \sim \text{Beta}(\alpha + z, \beta + n - z),$$

无需计算归一化常数即可解析确定后验，这正是共轭性带来的便利。代入本次数据：

- 先验分布设定为 $\text{Beta}(\alpha, \beta)$ ，其中根据行业历史 CTR 通常在 2% ~ 8% 之间，取 $\alpha = 10$ 、 $\beta = 200$ 。在试点测试中，有 $n = 200$ 次展示、 $z = 18$ 次点击，那么未点击数为 $n - z = 200 - 18 = 182$ 次。
- 通过共轭更新，后验分布为 $\text{Beta}(\alpha + 18, \beta + 182) = \text{Beta}(10 + 18, 200 + 182) = \text{Beta}(28, 382)$ 。

4.2 后验均值计算及与 observed CTR 的区分

- 后验均值：**对于 Beta 分布 $\text{Beta}(\alpha, \beta)$ ，其均值计算公式为 $\alpha/(\alpha + \beta)$ 。对于后验分布 $\text{Beta}(28, 382)$ ，后验均值为 $28/(28 + 382) = 28/410 = 0.0683$ ，即 6.83%。
- 与 observed CTR 的区分：**observed CTR（观测点击率）是根据试点测试数据直接计算得到的，即 $18/200 = 0.09$ ，也就是 9%，它仅仅基于本次试点测试的样本数据；而后验估计是结合了先验信息和试点测试数据、通过贝叶斯更新得到的对真实 CTR 的估计，它考虑了我们对行业的先验认知，比单纯的 observed CTR 更加全面和稳健。
- 后验均值为何落在 4.76% 与 9% 之间：**Beta-二项共轭下，后验均值恰好是先验均值与观测 CTR 的加权平均，权重即两者各自的等效样本量：

$$\mathbb{E}[\theta \mid \text{data}] = \frac{\alpha + \beta}{\alpha + \beta + n} \cdot \frac{\alpha}{\alpha + \beta} + \frac{n}{\alpha + \beta + n} \cdot \frac{z}{n} = \frac{210}{410} \times 4.76\% + \frac{200}{410} \times 9.00\% = 6.83\%.$$

本例中先验等效样本量(210)与试点样本量(200)几乎相当，权重约为 51.2% : 48.8%，因此后验均值几乎正好落在两者中间。这就是贝叶斯“收缩”(shrinkage)效应：小样本观测到的 9% 被行业经验向下拉回到 6.83%，从而避免了因 200 次展示的随机波动而高估广告效果。

4.3 不确定性的量化变化

除均值移动外，更新还改变了分布的离散程度，见表 2。

表 2 先验与后验的关键指标对比

指标	先验 $\text{Beta}(10, 200)$	后验 $\text{Beta}(28, 382)$	变化
均值	4.76%	6.83%	+2.07 个百分点
标准差	1.466%	1.244%	收窄 15.1%
95% 区间宽度	5.70 个百分点	4.86 个百分点	收窄 14.7%

不确定性确有下降，但幅度是**温和的（约 15%）而非剧烈的**——原因同样在于先验等效样本量（210）与试点数据量（200）相当，200 次展示所能提供的信息量与既有先

验大致持平，因此只能把不确定性压缩约六分之一。这一事实是第 6 部分建议“先灰度扩量、再全量上线”的直接依据。

4.4 先验分布与后验分布的比较

图 3 是先验分布与后验分布的比较图。先验分布为 $\text{Beta}(10, 200)$ ，均值约 4.76%；后验分布为 $\text{Beta}(28, 382)$ ，均值约 6.83%。后验分布相较于先验分布，峰值右移且更加集中，反映了结合新数据后对真实点击率估计的变化，不确定性降低。




图 3 先验分布与后验分布比较图：峰值右移且分布收窄

- **先验分布：**蓝色曲线代表先验分布，标注为“ $\text{Beta}(10, 200)$ ”，说明先验分布的参数为 $\alpha = 10$ 、 $\beta = 200$ 。同时还标注了“Effective n = 210”（先验等效展示次数为 $\alpha + \beta = 210$ ）、“Effective clicks = 10”（先验等效点击次数为 $\alpha = 10$ ）、“Prior Mean = 4.76%”（先验均值为 4.76%）。蓝色虚线标出先验均值位置。
- **后验分布：**红色曲线代表后验分布，标注为“ $\text{Beta}(28, 382)$ ”，说明后验分布的参数为 $\alpha = 28$ 、 $\beta = 382$ 。同时标注了“Effective n = 410”（后验等效展示次数为 $\alpha + \beta = 28 + 382 = 410$ ，即 210 次先验等效展示 + 200 次实际展示）、“Effective clicks = 28”（后验等效点击次数为 $\alpha = 28$ ，即 10 次先验等效点击 + 18 次实际点击）、“Posterior Mean = 6.83%”（后验均值为 6.83%）。红色虚线标出后验均值位置，粉色阴影为 95% 可信区间 [4.60%, 9.46%]。
- **口径说明：**图中先验与后验的“Effective n / Effective clicks”采用统一的**等效样本量**口径（即 $\alpha + \beta$ 与 α ），而非实际观测数。这样两个标注框才可直接对比，并直观体现“先验 210 + 数据 200 = 后验 410”的信息累加关系。
- **分布比较：**从图中可以看出，后验分布相较于先验分布峰值向右移动，说明结合新

的数据（展示和点击情况）后，对真实 CTR 的估计均值从 4.76% 提升到了 6.83%；同时后验分布比先验分布更加集中（标准差由 1.466% 降至 1.244%），表明不确定性有所降低。

4.5 信念更新解释

先验分布反映了我们在没有看到本次试点测试数据之前，基于行业历史经验对广告 CTR 的信念，其均值大约在 4.76% 附近。从图 3 中可以看出，当我们加入了试点测试的数据后，后验分布相较于先验分布发生了右移，峰值也有所变化，后验均值变为 6.83%。这表明我们的信念根据新的数据得到了更新，我们对广告真实 CTR 的估计变得更大，同时分布也变得更加集中，说明我们对 CTR 的不确定性在减小。也就是说，通过试点测试的数据，我们对广告的 CTR 有了更明确、并且更偏向于较高值的认知。

5 可信区间与贝叶斯解释 (Credible Interval and Bayesian Interpretation)

5.1 概念区分：可信区间 vs 置信区间

在进行区间估计时，需严格区分两大统计学派的不同逻辑：

- **频率学派的置信区间 (Confidence Interval)**：其含义为“若重复多次抽样，每次构造一个 95% 置信区间，则大约 95% 的区间会包含真实参数”。它无法对当前这一次试验的真值作出概率陈述。
- **贝叶斯学派的可信区间 (Credible Interval)**：直接描述为“在给定当前数据和先验信息下，真实参数落在该区间内的后验概率为 95%”。这正是业务决策者最直观、最需要的概率化解读。

本报告采用贝叶斯可信区间，使用后验分布的 2.5% 和 97.5% 分位数构造等尾可信区间 (Equal-tailed Credible Interval)。

5.2 95% 可信区间的计算

根据第 4 部分，后验分布为 $\theta | \text{Data} \sim \text{Beta}(28, 382)$ 。使用后验分布的 2.5% 和 97.5% 分位数计算 95% 可信区间，代码如下：

```
1 # 计算后验贝塔分布可信区间 stated
2
3 ci_low, ci_high = posterior.ppf([0.025, 0.975]) # 计算后验贝塔分布的95%等尾概率区间
4
5 display(Markdown(
6     f"95% credible interval: [{ci_low:.2%}, {ci_high:.2%}]"
7 ))
8 print(f"95% credible interval: [{ci_low:.2%}, {ci_high:.2%}]")
9
```

```
10 # 计算后验贝塔分布可信区间 completed
```

运行输出：

```
95% credible interval: [4.60%, 9.46%]
```

即该广告真实 CTR 的 95% 可信区间为 [4.60%, 9.46%]。

5.3 贝叶斯语言解读

根据当前先验信息（行业历史基准 2% ~ 8%）和试点观测数据（200 次展示，18 次点击），我们有 95% 的概率相信，该新横幅广告的真实 CTR 落在 4.60% 至 9.46% 之间。这是一个关于参数 θ 本身的直接概率陈述—— θ 在贝叶斯框架下是一个随机变量，我们对它的信念由后验分布 $\text{Beta}(28, 382)$ 完整刻画。它不涉及“重复抽样”这一假想过程，因此可以直接用于业务决策。

5.4 直接的后验概率陈述

可信区间只是后验分布的一种摘要。既然后验分布已经完整给出，我们可以针对任意业务关心的阈值直接计算概率 $P(\theta > t \mid \text{data})$ ，这是贝叶斯方法相对频率学派最实用的优势：

```
1 # 计算支撑上线决策的后验概率 stated
2
3 print('后验概率陈述 (Posterior probability statements) :')
4 for threshold, note in [(0.02, '行业最差基准'), (0.05, '行业中位水平'),
5                        (0.06, '业务盈亏平衡假设值'), (0.08, '行业最优基准')]:
6     prob = 1 - posterior.cdf(threshold)
7     print(f'    P( $\theta > \{threshold:.0\%\} \mid \text{data}) = \{prob:6.1\%\} \quad (\{note\})$ ')
8
9 # 计算支撑上线决策的后验概率 completed
```

运行输出：

```
后验概率陈述 (Posterior probability statements) :
P( $\theta > 2\% \mid \text{data}$ ) = 100.0%    (行业最差基准)
P( $\theta > 5\% \mid \text{data}$ ) = 94.0%    (行业中位水平)
P( $\theta > 6\% \mid \text{data}$ ) = 73.7%    (业务盈亏平衡假设值)
P( $\theta > 8\% \mid \text{data}$ ) = 17.1%    (行业最优基准)
```

整理为决策表，见表 3。

表 3 支撑上线决策的后验概率陈述

后验概率陈述	数值	业务含义
$P(\theta > 2\%)$	100.0%	几乎可以断定该广告不会跌至行业最差水平
$P(\theta > 5\%)$	94.0%	有 94% 把握该广告优于行业中位水平——这是支撑上线的核心证据
$P(\theta > 6\%)$	73.7%	约七成把握达到较好水平
$P(\theta > 8\%)$	17.1%	只有不到两成把握能触及行业最优水平，“爆款”预期应当保守
$P(\theta < 4.60\%)$	2.5%	最不利情形的发生概率很小

5.5 面向业务场景的通俗解读

将上述统计结果转化为该工作室可操作的业务语言：

- **核心结论：**结合历史经验和本次小规模测试，工作室有 95% 以上的把握认为，这则新广告的长期真实点击率至少能达到 4.60%，最高可能接近 9.46%。
- **对标基准：**该区间的最低点（4.60%）已接近行业历史区间的中位水平（5%），且远高于行业最差基准（2%）。这意味着，即使发生最不利的情况（后验分布的 2.5% 左尾），该广告的表现依然“不差”；而若达到区间上限，则效果“非常优秀”。
- **上限需保守看待：** $P(\theta > 8\%)$ 仅 17.1%，说明试点观测到的 9% 大概率含有随机波动的成分，不应把 9% 当作可复制的业绩预期；规划流量收益时应以后验均值 6.83% 为基准。
- **决策含义：**该广告呈现“低风险、中等上限”的特征——下行风险已被有效排除，但上限仍有相当不确定性，足以支撑下一步的推广决策，同时也说明值得先小步扩量以进一步收敛估计。

6 上线建议 (Launch Decision)

6.1 最终建议结论

推荐采用「小流量灰度扩量 + 全量上线兜底」的分阶段上线策略——既抓住当前试点验证的收益机会，也通过小步扩量进一步收敛 CTR 估计精度，平衡收益与潜在风险。

6.2 贝叶斯分析核心依据

本节严格只使用后验分布 $\text{Beta}(28, 382)$ 作为证据，不引用任何频率学派的检验结论。

- **后验均值明显上移**：经 Beta 共轭更新得到的后验均值为 6.83%，相比先验均值 4.76% 提升了 2.07 个百分点（相对提升 43.4%），说明在融合了行业经验之后，数据仍将我们对该广告的信念明确向上修正。
- **优于行业中位水平的后验概率高达 94.0%**：直接的概率陈述是 $P(\theta > 5\% \mid \text{data}) = 94.0\%$ ，即我们有 94% 的把握认为该广告优于行业中位水平。同时 $P(\theta > 2\% \mid \text{data}) \approx 100\%$ ，即“上线后大幅拉低整体流量效率”这一极端情形的后验概率几乎为零。（需要注意的是，可信区间下限 4.60% 对应的是 $P(\theta < 4.60\%) = 2.5\%$ ，而“低于行业中位 5%”的后验概率是 5.99%，两者不可混为一谈。）
- **上限存在不确定性，收益预期须保守**： $P(\theta > 8\% \mid \text{data})$ 仅为 17.1%，说明试点观测到的 9% 很可能包含随机波动。因此收益测算应以后验均值 6.83% 为基准，而非以 9% 为基准。
- **先验信念完成正向更新，但不确定性仅温和下降**：从先验 $\text{Beta}(10, 200)$ 到后验 $\text{Beta}(28, 382)$ ，分布明显右移，标准差由 1.466% 降至 1.244%，收窄约 15.1%。之所以收窄幅度有限，是因为先验等效样本量（210）与试点样本量（200）相当，200 次展示所携带的信息量与既有行业经验大致持平。**证据方向是明确的，但证据量还不足以把区间压到很窄**——这正是下一节主张分阶段上线而非直接全量的原因。

6.3 结合小样本特性的业务决策权衡

本次试点仅采集了 200 次曝光数据，虽已经通过贝叶斯框架融合了 210 次等效先验样本信息、总有效样本量为 410，但由上节可知不确定性仅收窄约 15%，仍存在进一步降低的空间，因此分阶段策略的价值优于直接全量上线。

1. **第一阶段：开启 30% 流量灰度**。选取游戏内 30% 的自然流量分配给新横幅广告，在不影响全量用户体验的前提下快速累积额外曝光数据。由于后验标准差近似按 $1/\sqrt{N_{\text{eff}}}$ 收缩 ($N_{\text{eff}} = \alpha + \beta$)，可精确预估收敛效果，见表 4。

表 4 灰度期新增曝光量与可信区间收敛效果预估

灰度期新增曝光 N	后验等效样本量	预计可信区间宽度	相对当前收窄
0 (当前)	410	4.86 个百分点	—
400	810	≈ 3.46 个百分点	$\approx 29\%$
1,000	1,410	≈ 2.62 个百分点	$\approx 46\%$
2,000	2,410	≈ 2.01 个百分点	$\approx 59\%$

即只需累积约 1,000 次额外曝光，即可将可信区间宽度压缩近一半。具体所需时长取决于工作室的日均曝光量，应按实际流量规模换算后确定灰度周期。

2. **第二阶段：全量覆盖上线。**设定明确的、由后验分布导出的放量判据：**若灰度期结束时更新后的后验分布仍满足 $P(\theta > 5\% \mid \text{全部数据}) \geq 90\%$ ，则执行全量上线**（该阈值与当前 94.0% 的水平相衔接，允许灰度数据带来小幅回落但不允许证据方向反转）；若该概率跌破 90%，则暂停放量并复核素材与投放位置。全量上线后可释放 6.83% 后验均值 CTR 对应的流量收益——具体的日增点击量需在获知工作室日均曝光量后测算，本报告数据不足以给出绝对数值。
3. **配套迭代动作。**上线后持续累积曝光与点击数据，每新增 200 次曝光就执行一次贝叶斯更新（把上一轮后验作为下一轮先验，这正是贝叶斯框架天然支持序贯更新的优势），动态迭代后验分布。后续可以基于不断收窄的可信区间，快速判断新素材的表现是否超过当前基准，搭建持续迭代的广告效果评估体系。

该策略既避免了盲目等待更大规模测试带来的机会成本损失，也不会因 200 次小样本的随机波动直接冒全量上线的风险，完全匹配本次贝叶斯分析输出的所有概率化结论，是当前业务场景下的最优决策。

6.4 先验敏感性分析（结论稳健性检验）

本报告的先验等效样本量为 210，与试点数据量 200 相当，属于较强的先验。为检验上线结论是否依赖于这一设定，我们在保持先验均值均为 5% 的前提下，改变先验强度重新计算后验：

```
1 # 先验敏感性分析 stated
2
3 for a, b, tag in [(10, 200, '本报告 Beta(10,200)'), (2, 38, '弱先验 Beta(2,38)'),
4                  (1, 1, '无信息先验 Beta(1,1)'), (25, 475, '强先验 Beta(25,475)')]:
5     post_alt = stats.beta(a + n_clicks, b + n_impressions - n_clicks)
6     lo, hi = post_alt.ppf([0.025, 0.975])
7     print(f'{tag} 等效样本量={a+b} 后验均值={post_alt.mean():.2%} '
8           f'95%CI=[{lo:.2%}, {hi:.2%}] P(θ>5%)={1-post_alt.cdf(0.05):.1%}')
9
10 # 先验敏感性分析 completed
```

运行结果整理为表 5。

表 5 先验敏感性分析（各先验均值均设为 5%）

先验设定	等效样本量	后验分布	后验均值	95% 可信区间	$P(\theta > 5\%)$
本报告 Beta(10, 200)	210	Beta(28, 382)	6.83%	[4.60%, 9.46%]	94.0%
弱先验 Beta(2, 38)	40	Beta(20, 220)	8.33%	[5.19%, 12.14%]	98.2%
无信息先验 Beta(1, 1)	2	Beta(19, 183)	9.41%	[5.79%, 13.78%]	99.4%
强先验 Beta(25, 475)	500	Beta(43, 657)	6.14%	[4.49%, 8.04%]	90.2%

结论：后验均值确实对先验强度敏感，随先验由强变弱在 6.14% ~ 9.41% 之间变动——这是先验样本量与数据样本量相当时的必然结果，也提示读者不应把 6.83% 当作唯一“正确”的点估计。但关键在于，**支撑上线决策的那条证据在所有设定下都成立：** $P(\theta > 5\%)$ 始终 $\geq 90.2\%$ 。也就是说，无论采用保守还是激进的先验，“该广告优于行业中位水平”这一判断都不会改变，本报告的上线建议对先验选择是稳健的。

7 小组成员角色与贡献

表 6 小组成员分工

姓名	角色与贡献
王金波	实验代码、第 3 部分二项似然函数
何漪雯	第 1 部分业务场景概述、第 2 部分先验概率密度分布图
李 敏	第 2 部分贝塔先验的选择与论证、第 5 部分可信区间与贝叶斯解释
丁 玲	第 4 部分后验计算和可视化、搭建报告结构及整合报告内容
刘海龙	第 6 部分上线建议、审查报告内容

附录 A 完整可运行代码

代码链接：https://github.com/woodywang/hpu/blob/master/6000-2/DSCI6000_hw2.py

以下为完整脚本，按顺序执行即可复现本报告全部数值结果与三张图表。脚本会自动将三张图保存到与报告同级的 `figures/` 目录（报告即以 `figures/xxx.png` 相对路径

引用), 因此重新运行脚本即可一并刷新报告中的所有插图。可整段粘贴到 Google Colab 单元格中直接运行 (Colab 已预装 `numpy / scipy / matplotlib`, 无需安装依赖)。

```
1 # Setup — run this cell first
2
3 import math
4 import os
5 import numpy as np
6 import matplotlib.pyplot as plt
7 from scipy import stats
8 from IPython.display import display, Markdown
9
10 # 设置绘图参数
11 plt.rcParams.update({
12     'figure.figsize': (9, 5),
13     'font.size': 12,
14     'axes.grid': True,
15     'grid.alpha': 0.25,
16 })
17
18 # 图片输出目录 (与 report.md 同级, 报告以 figures/xxx.png 相对路径引用)
19 FIG_DIR = 'figures'
20 os.makedirs(FIG_DIR, exist_ok=True)
21
22 def save_figure(filename):
23     """将当前图表保存到 FIG_DIR, 供 report.md 以文件链接方式引用。"""
24
25     path = os.path.join(FIG_DIR, filename)
26     plt.savefig(path, dpi=100)
27     print(f' [figure saved] {path}')
28
29 print('Setup complete.')
30
31 # 设置观测数据 stated
32
33 # 定义观测数据: 总展示数和总点击数
34 n_impressions = 200      # 总展示数
35 n_clicks = 18           # 总点击数
36
37 # 计算样本CTR: 总点击数 / 总展示数
38 sample_ctr = n_clicks / n_impressions
39
40 display(Markdown(
41     f"Pilot: **{n_clicks}** clicks out of **{n_impressions}** impressions → sample CTR = **{sample_ctr:.1%}**"
42 ))
43 print(f"Pilot: {n_clicks} clicks out of {n_impressions} impressions → sample CTR = {sample_ctr:.1%}")
44
45 # 设置观测数据 completed
46
47
48 # 选择先验贝塔分布的超参数值 stated
49
50 # 定义先验贝塔分布的超参数 $\alpha$ 和 $\beta$ 
```

```

51 alpha_prior = 10          # 先验贝塔分布超参数 $\alpha$ 
52 beta_prior = 200         # 先验贝塔分布超参数 $\beta$ 
53
54 # 计算先验贝塔分布的均值和标准差
55 prior = stats.beta(alpha_prior, beta_prior) # 创建贝塔分布对象
56 prior_mean = prior.mean() # 计算先验分布的均值
57 prior_sd = prior.std()    # 计算先验分布的标准差
58
59 # 计算先验贝塔分布的95%等尾概率区间
60 prior_ci_lower = prior.ppf(0.025)
61 prior_ci_upper = prior.ppf(0.975)
62
63 p = prior.cdf(0.08) - prior.cdf(0.02) # 计算probability mass over [0.02, 0.08]
64
65 display(Markdown(
66     f'''Prior: Beta({alpha_prior}, {beta_prior}) → mean = **{prior_mean:.2%}**, sd = **{prior_sd:.4f}**
67     95% 先验等尾概率区间 = [{prior_ci_lower:.2%}, {prior_ci_upper:.2%}]
68     probability mass over [0.02, 0.08] = **{p:.2%}**'''
69 ))
70 print(f'''Prior: Beta({alpha_prior}, {beta_prior}) → mean = {prior_mean:.2%}, sd = {prior_sd:.4f}
71     95% 先验等尾概率区间 = [{prior_ci_lower:.2%}, {prior_ci_upper:.2%}]
72     probability mass over [0.02, 0.08] = {p:.2%}''')
73
74 # 选择先验贝塔分布的超参数值 completed
75
76
77 # 绘制先验概率密度函数曲线图 stated
78
79 theta = np.linspace(0.001, 0.20, 500) #  $\theta$ 的取值范围
80
81 fig, ax = plt.subplots() # 创建图表和坐标轴对象
82
83 # 绘制先验概率密度函数曲线
84 ax.plot(theta, prior.pdf(theta), label='Prior', color='blue')
85
86 # 绘制95%等尾概率区间的高亮填充区域
87 ci_theta_range = np.linspace(prior_ci_lower, prior_ci_upper, 200)
88 ax.fill_between(ci_theta_range, prior.pdf(ci_theta_range), color='lightblue', alpha=0.4,
89                 label=f'95% Prior Probability Interval')
90
91 # 绘制先验均值的垂直标记线
92 ax.axvline(prior_mean, color='red', linestyle='--', linewidth=2,
93            label=f'Prior Mean = {prior_mean:.2%}')
94
95 # 辅助标记指定的2%-8%行业基准区间
96 ax.axvspan(0.02, 0.08, color='gray', alpha=0.15, label=f'Industry 2%-8% CTR Baseline')
97
98 ax.set_xlabel('True CTR ( $\theta$ )') # 设置x轴标签
99 ax.set_ylabel('Density') # 设置y轴标签
100 ax.set_title('Prior PDF of CTR ( $\theta$ ) with Mean and 95% Probability Interval') # 设置图表标题
101 ax.legend(fontsize=11) # 展示图例说明所有元素
102 plt.tight_layout() # 设置图表布局
103 save_figure('fig1_prior_pdf.png') # 保存图片供报告引用
104 plt.show() # 显示图表
105

```

```

106 # 绘制先验概率密度函数曲线图 completed
107
108
109 # 定义二项式似然函数与对数似然函数 stated
110
111 def binomial_likelihood(theta, n, z):
112     """Likelihood of observing z clicks in n impressions given  $\theta$ ."""
113
114     comb = math.factorial(n) / (math.factorial(z) * math.factorial(n - z))
115     return comb * (theta**z) * ((1 - theta)**(n - z))
116
117 def binomial_log_likelihood(theta, n, z):
118     """Log-likelihood of observing z clicks in n impressions given  $\theta$ ."""
119
120     return stats.binom.logpmf(z, n, theta)
121
122 # 手写公式与 scipy.stats.binom.pmf 互为交叉验证, 应得到相同结果
123 lik_manual = binomial_likelihood(sample_ctr, n_impressions, n_clicks)
124 lik_scipy = stats.binom.pmf(n_clicks, n_impressions, sample_ctr)
125 loglik = binomial_log_likelihood(sample_ctr, n_impressions, n_clicks)
126
127 print(f'''Likelihood of observing {n_clicks} clicks in {n_impressions} impressions at  $\theta = \{sample\_ctr:.2\}$ :
128     manual formula      = {lik_manual:.10f}
129     scipy binom.pmf     = {lik_scipy:.10f}
130     log-likelihood      = {loglik:.6f}    (= ln {lik_manual:.6f})''')
131
132 # 定义二项式似然函数与对数似然函数 completed
133
134
135 # 绘制二项似然函数曲线图 stated
136
137 # 似然函数是关于 $\theta$ 的函数: 给定观测数据(200次展示, 18次点击), 不同 $\theta$ 值的相对合理性
138 lik_curve = stats.binom.pmf(n_clicks, n_impressions, theta)
139
140 fig, ax = plt.subplots()
141
142 ax.plot(theta, lik_curve, color='green', label='Likelihood L( $\theta$ )')
143 ax.fill_between(theta, lik_curve, color='green', alpha=0.12)
144
145 # 似然函数在 $\theta = 18/200 = 9\%$ 处取得最大值 (最大似然估计MLE)
146 ax.axvline(sample_ctr, color='black', linestyle='--', linewidth=2,
147            label=f'MLE = observed CTR = {sample_ctr:.2%}')
148
149 ax.set_xlabel('True CTR ( $\theta$ )')
150 ax.set_ylabel('Likelihood L( $\theta$ ) = P(z=18 | n=200,  $\theta$ )')
151 ax.set_title('Binomial Likelihood of 18 Clicks out of 200 Impressions')
152 ax.legend(fontsize=11)
153 plt.tight_layout()
154 save_figure('fig2_likelihood.png') # 保存图片供报告引用
155 plt.show()
156
157 # 绘制二项似然函数曲线图 completed
158
159
160 # 计算后验贝塔分布 stated

```

```

161
162 # 计算后验贝塔分布的超参数
163 alpha_post = alpha_prior + n_clicks # 后验分布的超参数 $\alpha$ : 先验超参数 $\alpha$  + 观测到的点击数
164 beta_post = beta_prior + n_impressions - n_clicks # 后验分布的超参数 $\beta$ : 先验超参数 $\beta$  + 观测到的未点击数
165
166 # 计算后验贝塔分布的均值和标准差
167 posterior = stats.beta(alpha_post, beta_post) # 创建后验分布对象
168 post_mean = posterior.mean() # 计算后验分布的均值
169 post_sd = posterior.std() # 计算后验分布的标准差
170
171 # 后验均值是先验均值与观测CTR的加权平均, 权重为各自的等效样本量
172 w_prior = (alpha_prior + beta_prior) / (alpha_prior + beta_prior + n_impressions)
173 w_data = n_impressions / (alpha_prior + beta_prior + n_impressions)
174
175 display(Markdown(
176     f"Posterior: Beta({alpha_post}, {beta_post}) → mean CTR = **{post_mean:.2%}**, sd = **{post_sd:.4f}**"
177 ))
178 print(f'''Posterior: Beta({alpha_post}, {beta_post}) → mean CTR = {post_mean:.2%}, sd = {post_sd:.4f}
179     后验均值 = 先验权重 × 先验均值 + 数据权重 × 观测CTR
180         = {w_prior:.4f} × {prior_mean:.2%} + {w_data:.4f} × {sample_ctr:.2%} = {w_prior*prior_mean +
181         w_data*sample_ctr:.2%}
182     不确定性收窄: 先验sd {prior_sd:.4f} → 后验sd {post_sd:.4f}, 降幅 {1 - post_sd/prior_sd:.1%}''')
182
183 # 计算后验贝塔分布 completed
184
185
186 # 计算后验贝塔分布可信区间 stated
187
188 ci_low, ci_high = posterior.ppf([0.025, 0.975]) # 计算后验贝塔分布的95%等尾概率区间
189
190 display(Markdown(
191     f"**95% credible interval:** [{ci_low:.2%}, {ci_high:.2%}]"
192 ))
193 print(f"95% credible interval: [{ci_low:.2%}, {ci_high:.2%}]")
194
195 # 计算后验贝塔分布可信区间 completed
196
197
198 # 绘制先验贝塔分布与后验贝塔分布的比较图 stated
199
200 fig, ax = plt.subplots() # 创建图表和坐标轴对象
201
202 ax.plot(theta, prior.pdf(theta), label='Prior', color='blue') # 绘制先验贝塔分布的概率密度函数曲线
203 ax.plot(theta, posterior.pdf(theta), label='Posterior', color='red') # 绘制后验贝塔分布的概率密度函数曲线
204
205 # 绘制后验95%可信区间的高亮填充区域
206 post_ci_range = np.linspace(ci_low, ci_high, 200)
207 ax.fill_between(post_ci_range, posterior.pdf(post_ci_range), color='lightcoral', alpha=0.35,
208                 label=f"95% Credible Interval [{ci_low:.2%}, {ci_high:.2%}]")
209
210 # 绘制先验均值与后验均值的垂直标记线 (必须在 legend() 之前调用才会进入图例)
211 ax.axvline(prior_mean, color='blue', linestyle='--', linewidth=2,
212            label=f'Prior Mean = {prior_mean:.2%}')
213 ax.axvline(post_mean, color='red', linestyle='--', linewidth=2,
214            label=f'Posterior Mean = {post_mean:.2%}')

```

```

215
216 ax.set_xlabel('True CTR ( $\theta$ )')      # 设置x轴标签
217 ax.set_ylabel('Density')              # 设置y轴标签
218 ax.set_title('Comparison of Prior and Posterior Beta Distributions') # 设置图表标题
219 ax.legend(fontsize=9)                  # 展示图例说明所有元素
220
221 # 添加先验的文本标注 (展示次数与点击数均为"等效样本量"口径:  $\alpha+\beta$  与  $\alpha$ )
222 ax.text(0.015, 0.97, '\n'.join([
223     f'Beta({alpha_prior}, {beta_prior})',
224     f'Effective n = {alpha_prior + beta_prior}',
225     f'Effective clicks = {alpha_prior}',
226     f'Prior Mean = {prior_mean:.2%}']),
227     transform=ax.transAxes, fontsize=9.5, color='blue', ha='left', va='top')
228
229 # 添加后验的文本标注 (同为等效样本量口径:  $\alpha+\beta = 410$ ,  $\alpha = 28$ )
230 ax.text(0.52, 0.45, '\n'.join([
231     f'Beta({alpha_post}, {beta_post})',
232     f'Effective n = {alpha_post + beta_post}',
233     f'Effective clicks = {alpha_post}',
234     f'Posterior Mean = {post_mean:.2%}']),
235     transform=ax.transAxes, fontsize=9.5, color='red', ha='left', va='top')
236
237 plt.tight_layout()                      # 设置图表布局
238 save_figure('fig3_prior_vs_posterior.png') # 保存图片供报告引用
239 plt.show()                              # 显示图表
240
241 # 绘制先验贝塔分布与后验贝塔分布的比较图 completed
242
243
244 # 计算支撑上线决策的后验概率 stated
245
246 # 作业要求"仅以贝叶斯后验结果作为证据", 最直接的证据即对 $\theta$ 的后验概率陈述
247 print('后验概率陈述 (Posterior probability statements) :')
248 for threshold, note in [(0.02, '行业最差基准'), (0.05, '行业中位水平'),
249     (0.06, '业务盈亏平衡假设值'), (0.08, '行业最优基准')]:
250     prob = 1 - posterior.cdf(threshold)
251     print(f'    P( $\theta > \{threshold:.0\%\} \mid \text{data}\} = \{prob:6.1\%\} \quad (\{note\})$ ')
252
253 # 后验分布落在行业基准区间之外 (即优于行业上限) 的概率
254 print(f'\n    P( $\theta < \{ci_low:.2\%\} \mid \text{data}\} = \{posterior.cdf(ci_low):.1\%\} \quad (\text{可信区间下限, 即最不利情形})$ ')
255
256 # 计算支撑上线决策的后验概率 completed
257
258
259 # 先验敏感性分析 stated
260
261 # 先验等效样本量(210)与试点数据量(200)相当, 先验较强, 需检验结论对先验设定的稳健性
262 print('先验敏感性分析 (Prior sensitivity analysis, 各先验均值均设为5%) :')
263 print(f'{"先验设定":<26}{"等效样本量":>10}{"后验均值":>10}{"95%可信区间":>22}{"P( $\theta>5\%$ ):>10}")
264 for a, b, tag in [(10, 200, '本报告 Beta(10,200)'),
265     (2, 38, '弱先验 Beta(2,38)'),
266     (1, 1, '无信息先验 Beta(1,1)'),
267     (25, 475, '强先验 Beta(25,475)')]:
268     post_alt = stats.beta(a + n_clicks, b + n_impressions - n_clicks)
269     lo, hi = post_alt.ppf([0.025, 0.975])

```

```
270     print(f'{tag:<26}{a+b:>10}{post_alt.mean():>10.2%}'  
271           f'f" [{lo:.2%}, {hi:.2%}]" :>22}{1-post_alt.cdf(0.05):>10.1%}')  
272  
273 print('\n结论：后验均值随先验强度在 6.14%~9.41% 之间变动，但  $P(\theta > 5\%)$  在所有设定下均  $\geq 90\%$ , '  
274 print('      即"该广告优于行业中位水平"这一上线依据对先验选择是稳健的。')  
275  
276 # 先验敏感性分析 completed
```